

CLASSIFICAÇÃO DE CRISES EPILÉPTICAS POR DECOMPOSIÇÃO DE MODOS DE SINAIS DE EEG

VINÍCIUS R. CARVALHO^{1,2}, EDUARDO M.A.M. MENDES^{1,2}, MÁRCIO F.D. MORAES¹,

ANTÔNIO DE PÁDUA BRAGA²

¹ Centro de Tecnologia e Pesquisa em Magneto-Ressonância, Escola de Engenharia, Universidade Federal de Minas Gerais, Av. Antônio Carlos, 6627, Pampulha, 31270 901 Belo Horizonte, Minas Gerais, Brasil

² Programa de Pós-Graduação em Engenharia Elétrica – Universidade Federal de Minas Gerais – Av. Antônio Carlos 6627, 31270-901, Belo Horizonte, MG, Brasil.

vrcarva@gmail.com, emmendes@cpdee.ufmg.br, mfdm@icb.ufmg.br,
apbraga@cpdee.ufmg.br

Abstract— In this work, a methodology for feature extraction and classification of EEG signals is proposed. The signals from ictal, interictal and normal classes are decomposed into N modes according to two methods: Empirical Mode Decomposition and Empirical Wavelet Transform. The extracted features of each mode are then classified using K-Nearest Neighbours and Bagging of Decision Trees. Using the proposed methodology, Maximum Accuracy rate of 95.7%, Sensitivity of 96.78% and Specificity of 97.83% were found. These results are in agreement with those reported in the available literature.

Keywords— EEG, Empirical Mode Decomposition (EMD), Empirical Wavelet Transform (EWT), seizure detection, KNN.

Resumo — Neste trabalho, propomos uma metodologia de extração de características e classificação de sinais de EEG em três classes: ictal, normal e interictal. Os sinais são decompostos em N modos por dois métodos: Decomposição Empírica de Modos e Transformada Empírica de Wavelet, e as características extraídas de cada modo são utilizadas pelos classificadores de K-vizinhos mais próximos e por Conjunto de Árvore de Decisões. Taxas de exatidão de até 95.7 %, Sensitividade de 96.78% e especificidade de 97.83% foram obtidas, resultados de acordo com outros trabalhos do tipo na literatura.

Palavras-chave — EEG, Empirical Mode Decomposition (EMD), Empirical Wavelet Transform (EWT), detecção de crises epiléticas, KNN.

1 Introdução

Aproximadamente 1% da população mundial sofre de epilepsia, o segundo tipo de distúrbio do sistema nervoso mais comum no mundo, perdendo apenas para AVC (Engel 1989). O número de novos casos varia de 24 a 53 a cada 100.000 pessoas. Um dos fatores que contribui para sua alta taxa de incidência é o grande número de causas que levam a tal condição, tais como: fatores genéticos, falhas no desenvolvimento, convulsões febris, traumas e infecções no sistema nervoso, isquemia, tumores, entre outros. Apesar de ocorrer em grupos de todas as idades, crianças e idosos possuem as maiores taxas de incidência de epilepsia (Iasemidis 2003).

A epilepsia é caracterizada pelo disparo anormal, em geral síncrono e de alta intensidade, de grupos de neurônios no cérebro. Esta quebra nos padrões normais de funcionamento de neurônios pode invocar desde sensações, comportamentos e sentidos estranhos, até convulsões, com espasmos musculares e possível perda de consciência. Caso uma pessoa tenha uma crise de convulsão, não significa necessariamente que ela sofre de epilepsia; são necessárias duas ou mais crises para que a pessoa seja diagnosticada com esta condição. O mesmo ocorre com convulsões febris e psicogênicas (Frazen 2000).

Normalmente, a detecção de crises epiléticas é feita por inspeção visual de sinais de EEG por um

neurofisiologista experiente (Bajaj & Pachori 2013) que leva em conta: frequência, amplitude, regularidade das formas de onda, fotoestimulação, escalas espaciais e persistência temporal das anomalias do sinal (Adeli et al. 2003). Em geral, as frequências de interesse das componentes de um EEG em uma análise clínica e fisiológica estão entre 0.3 e 30Hz, aproximadamente (Adeli et al. 2003). Esta faixa de frequência é, por sua vez, dividida em uma série de bandas, denominadas: Delta (< 4Hz), Theta (4 – 8 Hz), Alpha (8-14 Hz) e Beta (14-30 Hz).

O método de inspeção visual, além de trabalhoso e demorado, pode ser impreciso (especialmente para séries longas). Os resultados da análise de uma mesma série feita por dois profissionais podem ser diferentes devido à subjetividade inerente a tal método (Bajaj & Pachori 2013). Além disso, há uma série de componentes e características presentes no sinal que dificilmente são detectados por meio de simples inspeção visual. Deste modo, algoritmos de análise e processamento de sinais desempenham um papel importante no diagnóstico clínico de epilepsia, ao extrair características e informações de séries temporais de EEG de um ou vários canais.

Durante períodos de crise epilética (período ictal), há um aumento considerável na taxa de disparo dos neurônios da região afetada do cérebro, refletindo em um aumento na amplitude dos sinais de EEG. Além disso, o período ictal é caracterizado pelo apa-

recimento de padrões de disparo sincronizados entre grupos de neurônios, que começam e terminam de modo ainda não totalmente compreendido (Iasemidis et al. 2004). A compreensão da dinâmica e dos parâmetros de mudança do EEG que diferem períodos normais do EEG de períodos ictais e inter-ictais é fundamental para o entendimento de como ocorrem crises epiléticas, de modo a auxiliar no controle e na predição desta condição (Adeli et al. 2003).

Para a extração de informações relevantes de registros de séries temporais, uma variedade de algoritmos e técnicas de análise e processamento de sinais foi desenvolvida ao longo dos anos (Mormann et al. 2007). A maioria dos métodos considera que os sinais de EEG são gerados por sistemas lineares altamente complexos, resultando em características de não-estacionariedade ou imprevisibilidade. Outros métodos, por sua vez, podem interpretar sinais de EEG como saídas de um sistema determinístico com relativa baixa complexidade, mas com elementos altamente não-lineares (Lehnertz 1999). Estudos indicam que sinais de EEG possuem componentes de frequência não-estacionários (Adeli et al. 2003)(Tzallas et al. 2007). Deste modo, a análise por meio da transformada de Fourier em sinais de EEG é limitada, pois esta assume que o sinal em questão é estacionário. Assim, métodos mais recentes para análise de sinais de EEG de pacientes epiléticos utilizam abordagens do tipo tempo-frequência, extração de parâmetros ou métodos não lineares, como Dimensão Fractal, Entropia ou Correlação de Dimensão (Pachori 2008).

Segundo (Lehnertz 1999), técnicas de análise de séries temporais não lineares (NTSA) podem permitir a caracterização de diferentes propriedades dinâmicas e estáticas de séries de EEG, que não poderiam ser obtidos por métodos lineares convencionais. Geralmente, a extração de características não-lineares de séries temporais é dificultada no caso destas serem relativamente curtas, ruidosas e de sistemas não estacionários (o que é o caso em várias análises de EEG). Porém, garantindo a interpretação cuidadosa e o processamento adequado dos sinais, há crescente evidência na literatura que informações obtidas por meio de métodos NTSA são superiores as obtidas por meio de métodos paramétricos e não paramétricos convencionais (Lehnertz 1999). Esta afirmação é especialmente válida para o entendimento da dinâmica espaço-temporal de áreas epileptogênicas primárias, essenciais em diagnósticos pré-cirúrgicos (Lehnertz 1999).

Nos últimos anos, alguns trabalhos como (Martis et al. 2012; Labate et al. 2013; Bajaj & Pachori 2011; Bajaj & Pachori 2013) têm proposto a detecção e classificação de crises por meio de um método de análise tempo-frequência denominado Decomposição Empírica de Modos (EMD – Empirical Mode Decomposition), apresentado em (Huang et al. 1998). Este método tem se destacado por sua simplicidade e adaptabilidade, em relação às características do sinal e à escala. Em (Pachori 2008), as frequências médias dos modos resultantes da EMD são utilizadas para

classificar entre período ictal e período livre de crises em sinais de EEG. Um problema de classificação semelhante é abordado em (Oweis & Abdulhay 2011) por meio da análise de frequências ponderadas.

Neste trabalho, são aplicados dois métodos de decomposição de sinais, EMD (citado anteriormente) e Transformada de Wavelet Empírica (EWT) (Gilles 2013), a fim de extrair características para classificação de sinais de EEG normal, ictal e inter-ictal. O primeiro método já possui trabalhos na literatura (citados no parágrafo anterior) com aplicações semelhantes. Porém, embora existam trabalhos empregando Wavelets para detecção e classificação de crises (Adeli et al. 2007; Adeli et al. 2003; Bahcivan & Zhang 2001), não há ainda estudos utilizando a Transformada de Wavelet Empírica (EWT) para este propósito. Seu uso torna-se interessante ao considerar as vantagens deste método, segundo (Gilles 2013), em relação à decomposição EMD. Uma dessas vantagens é a possibilidade de escolher o número de modos em que o sinal será decomposto, evitando assim a sobre-estimação de modos que pode ocorrer na decomposição por EMD (Gilles 2013).

O restante deste trabalho é organizado em três seções. Na próxima Seção (2), a metodologia utilizada é apresentada, contendo os dados, métodos e resumos teóricos sobre as ferramentas utilizadas. Na Seção 3, os resultados obtidos são apresentados e analisados. Na Seção 4, comentários conclusivos são feitos a respeito do trabalho.

2 Metodologia

2.1 Dados Utilizados

Os dados de EEG utilizados neste trabalho foram obtidos da Base de Dados da Universidade de Bonn¹. A base de dados original é dividida em cinco conjuntos: *Z, O, N, F, S* (Andrzejak et al. 2001). Cada uma é composta de 100 séries temporais com duração de 23.6s e frequência amostral de 173.61 Hz. Os conjuntos *Z* e *O* correspondem a séries de EEG extra cranial, de cinco voluntários saudáveis (com olhos abertos e fechados, respectivamente). As outras três séries são de pacientes epiléticos, com a série *S* obtida durante um período de crise, e as séries *F* e *N* (com eletrodos localizados na zona epileptogênica e hipocampo oposto, respectivamente) durante períodos livres de crise. Neste estudo, foram utilizados três conjuntos; *S, F* e *Z*, correspondendo às classes Ictal, Interictal e Normal, respectivamente. Amostras de cada classe e os respectivos espectros de frequência, calculados por meio da FFT, são mostradas na Figura 1.

Como recomendado na página onde os dados são disponibilizados, a primeira etapa de processamento deve incluir a filtragem por um filtro passa-baixas. Neste estudo, aplicamos, a cada amos-

¹ Dados disponíveis em http://epileptologie-bonn.de/cms/front_content.php?idcat=193

tra, um filtro *Butterworth* de 2ª ordem, com frequência de corte em 40Hz,.

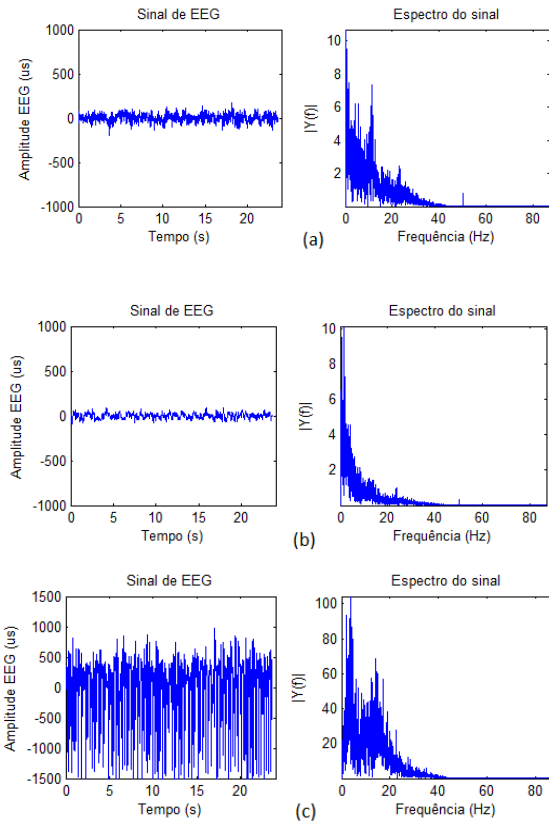


Figura 1. Sinais de EEG e respectivos espectros de frequência (a) Normal (b) Inter ictal (c) Ictal

2.2 Decomposição Empírica de Modos - EMD

A Decomposição Empírica de Modos (EMD) (Huang et al. 1998) é um método que se destaca pela adaptabilidade, não dependendo de características como linearidade ou estacionariedade. Este método busca dividir o sinal analisado em uma série de Funções de Modo Intrínseco (IMFs), onde cada uma deve satisfazer a duas condições relativamente simples:

- I. No segmento a ser analisado, o número de extremos deve ser igual ou diferir de um em relação ao número de cruzamentos em zero.
- II. Em todos os pontos, o valor médio do envelope definido pelos máximos locais e do envelope definido pelos mínimos locais deve ser igual a zero.

O algoritmo proposto em (Huang et al. 1998) para a obtenção destas IMFs consiste nos seguintes passos:

- 1) Passo 1: Dada uma série temporal $x(t)$, encontrar os máximos e mínimos locais.
- 2) Gerar os envelopes e_{max} e e_{min} por meio de interpolação de spline cúbica, dos máximos e mínimos, respectivamente.

- 3) Calcular a média dos envelopes, $m_i(t) = (e_{max}(t) + e_{min}(t))/2$
- 4) Subtrair o valor encontrado anteriormente do sinal: $h(t) = x(t) - m_i(t)$. Se $h(t)$ satisfazer as condições apresentadas anteriormente para uma IMF, uma IMF $c_i(t) = h(t)$ é encontrada.
- 5) Um novo resíduo r é gerado: $r(t) = x(t) - c_i(t)$. Repetir os passos 1 a 4, aplicados ao resíduo r , de modo a encontrar as IMFs restantes. O processo para quando não é mais possível computar uma IMF de um resíduo, que então é definido como resíduo final, r_M .

O sinal então é decomposto em determinado número de IMFs ($c_i(t)$), mais um resíduo, podendo ser representado e reconstruído por (1),

$$x(t) = r_M + \sum_{i=1}^N c_i(t) \quad (1)$$

onde N é o número total de IMFs encontradas.

A implementação em MATLAB do método EMD neste trabalho foi baseada nos códigos disponíveis em [http://perso.ens-lyon.fr/patrick.flandrin/emd.htm].

2.3 Transformada de Wavelet Empírica - EWT

Outro método de decomposição adaptativa é apresentado em (Gilles 2013), denominado Transformada de Wavelet Empírica (EWT). Como no EMD, este método busca extrair as componentes oscilatórias moduladas em amplitude (AM) e frequência (FM) de um sinal, considerando-as como tendo suporte compacto no espectro de Fourier. Ao contrário de Transformadas Wavelet tradicionais, que utilizam uma estrutura pré-definida de bancos de filtros, a EWT define os suportes dos filtros de acordo com a distribuição espectral do sinal, de maneira totalmente adaptativa. Algumas considerações são feitas para a análise: (1) o sinal deve ser real, devido à necessidade de simetria e (2), um eixo de frequências normalizado com periodicidade de 2π é considerado, com a análise restrita a $[0, \pi]$, devido ao critério de amostragem de Shannon.

Um número N de modos é definido a priori, determinando em quantos segmentos o espectro no intervalo $[0, \pi]$ será particionado. Dos $N+1$ limites de frequência a serem determinados, dois limites já são pré-definidos (ω_0 e ω_N), correspondendo às frequências de 0 e π , respectivamente. Os $N-1$ limites restantes são definidos de acordo com a distribuição do espectro de frequência do sinal: os $N-1$ máximos locais são encontrados, e os limites ω_n ($n = 1, 2, \dots, N-1$) são definidos como os pontos médios entre dois máximos consecutivos. Apesar de em (Gilles 2013) esta divisão ser feita sobre o espectro resultante da Transformada de Fourier, neste trabalho consideramos a segmentação feita com base na análise de

máximos locais da distribuição de Densidade de Potência Espectral (PSD). A divisão por meio da FFT resultou, muitas vezes, na divisão de uma componente em mais de um modo, de modo que uma representação mais suave do espectro (neste caso, feita por meio da densidade espectral) foi mais adequada para a detecção de máximos locais e segmentação. Para a estimação da PSD, foi utilizado o método de *Welch* (Welch 1967), que divide o sinal em N segmentos com um grau de sobreposição, aplica janelas no domínio do tempo a cada uma, e determina a DFT e sua magnitude quadrática, tirando então a média dos resultados ao longo do tempo. A segmentação de um sinal de EEG normal em nove modos é mostrada na Figura 2.

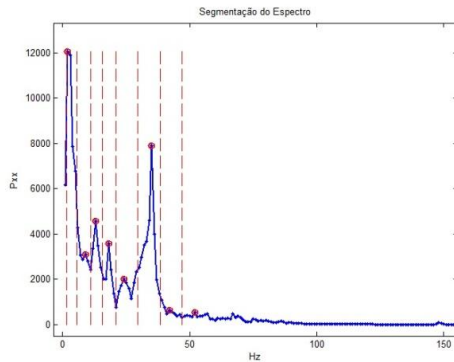


Figura 2: Segmentação do Espectro de um EEG normal

Definidos os limites ω_n , temos os segmentos $A_n = [\omega_{n-1}, \omega_n]$, preenchendo o intervalo $[0, \pi]$. Os limites de cada segmento são caracterizados por uma fase de transição centrada no respectivo ω_n e com largura $2\tau_n$. Cada segmento está associado a um filtro passa-faixa (passa-baixas no caso do segmento em ω_0), cuja construção está de acordo com Wavelets de Littlewood-Paley e Meyer (Daubechies 1992). São definidas então, uma função de escala empírica, $\phi_n(\omega)$, e a Wavelet Empírica $\psi_n(\omega)$, que são construídas de tal modo que um Frame justo é obtido. Maiores detalhes sobre a construção de tais funções são dados em (Gilles 2013).

Com as condições para construção de um Frame Justo satisfeitas, a EWT é definida de modo semelhante a uma Transformada de Wavelet tradicional, onde os detalhes são dados pelo produto interno da Função Wavelet com o sinal, e a aproximação é dada pelo produto interno do sinal com a Função de Escala.

A implementação em MATLAB do método EWT foi baseada nos códigos disponíveis em [http://www.mathworks.com/matlabcentral/fileexchange/42141-empirical-wavelet-transforms].

2.4 Extração de Características

Tanto as IMFs retornadas pelo método EMD, quanto os modos empíricos da EWT, podem ser considerados como sinais modulados em amplitude e frequência. Assim, a extração de características é

feita de acordo com características do espectro de cada modo, semelhante à abordagem empregada por (Martis et al. 2012). O artigo citado utiliza a estimação da Densidade Espectral (PSD) por um modelo Auto Regressivo pelo método de Burg. Porém, a PSD de cada modo de cada sinal é diferente e muitas vezes imprevisível, dificultando a estimativa por este método (em especial a escolha de ordem, que pode variar para diferentes modos de um sinal). Assim, neste trabalho optamos por fazer a estimativa da PSD de cada modo pelo método de *Welch*, utilizado também na partição de frequências da EWT e citado anteriormente.

Como em (Martis et al. 2012), a primeira característica extraída é dada pela Energia Espectral (EE), definida por:

$$EE = \frac{1}{N} \sum_{f=0}^{\frac{f_s}{2}} P_{XX}(f) \quad (2)$$

onde N é o número total de coeficientes espectrais estimados, e P_{XX} é a PSD estimada pelo método de *Welch*. A segunda característica é dada pela Entropia Espectral (EntE) como mostrado abaixo;

$$EntE = - \sum_{f=0}^{\frac{f_s}{2}} \bar{P}_{XX}(f) \log[\bar{P}_{XX}(f)] \quad (3)$$

onde \bar{P}_{XX} é a densidade espectral normalizada. As outras três características estão relacionadas pela componente principal de frequência do modo analisado. Após a determinação do máximo global de P_{XX} , a magnitude correspondente é extraída (determinando o Pico Espectral, PE), assim como a frequência associada (F), definindo a 3ª e 4ª característica, respectivamente. A última característica extraída é definida como centroide espectral (CE), que pode ser vista como o “centro de massa” da PSD, com a seguinte fórmula;

$$CE = \frac{\sum_{f=0}^{\frac{f_s}{2}} \omega(f) M(f)}{\sum_{f=0}^{\frac{f_s}{2}} M(f)} \quad (4)$$

onde f é a “bin” de frequência, e $\omega(f)$ e $M(f)$ a frequência central e Magnitude do espectro correspondendo à “bin” f , respectivamente.

2.5 Seleção de Características e Classificação

Como o número de características extraídas de cada sinal é relativamente grande (como veremos a seguir), e nem todas as características são relevantes para a discriminação entre diferentes classes de sinal, torna-se desejável a seleção de um conjunto de características relevantes antes da aplicação do algoritmo classificador. O primeiro método para seleção foi baseado na Análise de Variância, por meio do teste ANOVA. O valor p de cada característica é retornado, e todos são ordenados em ordem crescente. Deste modo o menor índice p corresponde à característica

com maior probabilidade de rejeição de hipótese nula, ou seja, com alta capacidade de discriminar diferentes classes.

Como primeiro método de classificação, associado à seleção de características por ANOVA, foi utilizado a busca por vizinhos mais próximos (KNN) (Hellman 1970; Cover & Hart 1967), um método simples de classificação baseado no cálculo de distâncias (neste caso, utilizamos distância Euclidiana) entre variáveis.

O segundo método envolve as etapas de seleção e classificação por meio de um tipo de aprendizado de conjuntos, denominado *Bagging* (de *Bootstrap Aggregation*), aplicado a uma árvore de decisões (CART). Este método, proposto em (Breiman 1996), consiste basicamente na obtenção de novas amostras, dado um único conjunto de amostras de treinamento, de modo a reduzir a variância e evitar a sobreparametrização do modelo. A árvore de decisões, por sua vez, prevê respostas para determinadas amostras, de acordo com regras de decisão. Estas regras vão desde a raiz (início) até nós terminais ou folhas, que contém a decisão sobre a classe pertencente à determinada amostra. Este é um método supervisionado, onde dados de treinamento são submetidos ao algoritmo junto com as classes reais de cada amostra. A etapa de teste consiste em fornecer novos dados ao algoritmo e comparar os resultados com as respectivas classes do novo conjunto.

Resumindo, foram empregados dois métodos de decomposição para extração de características (EMD e EWT). Estas características, por sua vez, são selecionadas e usadas para classificação de acordo com dois métodos, (ANOVA + KNN) e (*Bagging* + CART).

3 Resultados e Discussão

Três classes de EEG foram analisadas: Normal, Ictal e Inter-ictal, cada uma com 100 amostras. As amostras foram divididas entre conjuntos de treinamento (70 amostras) e de teste (30 amostras), respectivamente. As etapas de seleção de características e classificação foram executadas 30 vezes, permutando-se a ordem das amostras a cada execução, de modo a variar os grupos de treinamento e teste. Ao final das iterações, a média e desvio padrão dos indicadores de desempenho são calculadas, de modo a avaliar o viés dos resultados em relação à seleção e divisão de amostras. Foram selecionados quatro parâmetros de avaliação de desempenho, geralmente utilizados em problemas de classificação.

Um dos parâmetros mais comuns para avaliação de desempenho de um classificador é relacionado com seu número de previsões incorretas. Assim, é definido o primeiro parâmetro de desempenho, Exatidão, que é dada pelo número de classificações corretas das amostras de teste sobre o número total destas amostras. Apesar de ser o mais intuitivo, tal parâmetro nem sempre é o melhor para avaliar um método de classificação. Por isso, é definida a curva

ROC (*Receiver Operating Characteristic*), dada pela proporção de Verdadeiros Positivos (VP) sobre Falsos Positivos (FP), à medida que se varia o *threshold* (de 0 a 1) de classificação de uma classe definida como positiva (neste caso a classe positiva é a Ictal, com as outras definidas negativas). Porém, um valor escalar é desejável para fins de comparação, de modo que a área sobre a curva (AUC) ROC é escolhida. Quanto mais próxima o parâmetro AUC está de 1, melhor é o classificador. Para fins de comparação com outros trabalhos, também escolhemos a Sensitividade ($TP/(FN+TP)$) e Especificidade ($VN/(VN+FP)$) como parâmetros de desempenho.

As amostras de cada classe foram submetidas aos métodos de decomposição EMD e EWT, seguidas da extração de características EE, EntE, PE, F e CE de cada modo. A extração por EMD resultou em $N = 9$ IMFs para cada amostra, sendo que o mesmo número de modos foi utilizado para o método EWT. Para cada modo de um sinal foram obtidas 5 características, resultando em 45 características totais para cada sinal ou amostra.

No primeiro método de classificação, organizamos as características extraídas de acordo com o valor p retornado pelo teste ANOVA. Em seguida, o classificador KNN foi aplicado sucessivamente, aumentando o número de características (N) a cada iteração. A métrica de distância escolhida foi a Euclidiana, e o número de vizinhos é igual a 6. Tais escolhas foram determinadas empiricamente.

No segundo método de classificação, por *bagging* a um conjunto de Árvore de decisões (CART), testes iniciais foram feitos de modo a determinar os parâmetros ideais do modelo. Estes testes incluem o tamanho ótimo de folha (feito variando-se o tamanho para diferentes conjuntos de árvores), e o conjunto de características relevantes para o modelo. As características são ordenadas por ordem de importância, determinada pelo aumento do erro de predição ao permutá-las em testes realizados em amostras “*out of bag*”, para todas as árvores do conjunto. Assim que os parâmetros são definidos e as variáveis são ordenadas, o modelo é testado com o aumento sucessivo de características (N), do mesmo modo que o primeiro método de classificação.

Os resultados para os métodos ANOVA + KNN e *Bagging* + CART aplicado à decomposição EMD são mostrados na Tabela 1 e Tabela 2, respectivamente. Os valores são dados em termos de média e desvio padrão de 10 testes, permutando-se a ordem das amostras para a classificação.

Para o método ANOVA + KNN, o uso de 11 características resultou no melhor desempenho para os parâmetros escolhidos. Com 12 atributos em diante, o desempenho é degradado ligeiramente. Com a classificação por *Bagging* + CART, o desempenho ótimo é observado com o uso de 12 características, permanecendo estável quando novos atributos são incluídos. O desempenho geral deste método superou ligeiramente a classificação pelo método ANOVA+KNN, em especial no quesito AUC da curva ROC e especificidade.

Tabela 1. Desempenho de Características extraídas de EMD, ranqueadas por ANOVA e classificação por KNN.

N	Exatidão (%)	AUC	Sensitividade (%)	Especificidade (%)
1	63,22 ± 4,36	0,736 ± 0,052	58,33 ± 7,67	82,22 ± 7,34
2	70,85 ± 5,03	0,838 ± 0,073	70,56 ± 13,84	86,94 ± 6,81
3	71,22 ± 4,78	0,859 ± 0,061	69,78 ± 12,59	89,33 ± 7,53
4	74,96 ± 3,19	0,975 ± 0,018	96,22 ± 3,58	97,89 ± 1,31
5	85,37 ± 3,67	0,976 ± 0,018	95,89 ± 3,68	98,17 ± 1,26
6	85,93 ± 4,39	0,978 ± 0,017	96,11 ± 3,82	98,17 ± 1,26
7	91,15 ± 2,81	0,978 ± 0,017	96,56 ± 3,66	98,00 ± 1,27
8	92,00 ± 3,00	0,978 ± 0,017	96,56 ± 3,66	98,11 ± 1,22
9	92,89 ± 2,75	0,978 ± 0,018	96,44 ± 3,60	98,11 ± 1,22
10	93,30 ± 2,70	0,977 ± 0,017	96,33 ± 3,54	98,11 ± 1,22
11	93,56 ± 2,65	0,977 ± 0,019	96,33 ± 3,54	97,94 ± 1,62
12	93,44 ± 2,66	0,977 ± 0,019	96,33 ± 3,54	98,00 ± 1,54
13	93,11 ± 2,74	0,978 ± 0,019	96,33 ± 3,54	97,56 ± 2,30
14	93,00 ± 2,80	0,978 ± 0,019	96,33 ± 3,54	97,56 ± 2,30
15	92,89 ± 2,60	0,979 ± 0,019	96,44 ± 3,60	97,44 ± 2,58
16	92,81 ± 2,85	0,980 ± 0,019	96,44 ± 3,60	97,39 ± 2,61
17	92,37 ± 2,94	0,980 ± 0,020	96,00 ± 4,41	97,11 ± 2,62
18	91,44 ± 3,21	0,985 ± 0,018	95,33 ± 4,84	96,83 ± 2,60
19	63,22 ± 4,36	0,736 ± 0,052	58,33 ± 7,67	82,22 ± 7,34
20	70,85 ± 5,03	0,838 ± 0,073	70,56 ± 13,84	86,94 ± 6,81

Tabela 2. Desempenho de Características extraídas de EMD, classificação por Bagging + CART.

N	Exatidão (%)	AUC	Sensitividade (%)	Especificidade (%)
1	72,26 ± 5,31	0,890 ± 0,116	77,11 ± 19,99	94,44 ± 4,45
2	84,96 ± 5,82	0,970 ± 0,056	90,56 ± 12,32	96,06 ± 2,82
3	89,89 ± 2,60	0,989 ± 0,011	93,78 ± 5,16	97,06 ± 2,26
4	91,81 ± 3,20	0,992 ± 0,008	95,67 ± 4,30	97,44 ± 2,13
5	92,67 ± 3,14	0,994 ± 0,006	95,33 ± 4,76	97,67 ± 1,84
6	93,96 ± 2,78	0,994 ± 0,008	95,22 ± 4,61	97,89 ± 1,90
7	94,22 ± 2,66	0,994 ± 0,006	96,00 ± 4,14	97,78 ± 1,87
8	94,63 ± 2,43	0,995 ± 0,004	96,44 ± 3,71	98,00 ± 1,66
9	94,81 ± 2,63	0,995 ± 0,006	96,33 ± 3,85	98,00 ± 1,60
10	94,89 ± 2,40	0,995 ± 0,005	96,11 ± 3,82	97,78 ± 1,82
11	94,89 ± 2,27	0,995 ± 0,005	96,33 ± 4,04	97,94 ± 1,62
12	95,04 ± 2,26	0,995 ± 0,005	96,56 ± 3,66	97,83 ± 1,65
13	95,07 ± 2,16	0,995 ± 0,005	96,56 ± 3,66	97,94 ± 1,56
14	95,04 ± 2,06	0,995 ± 0,005	96,56 ± 3,44	97,83 ± 1,59
15	95,37 ± 2,17	0,995 ± 0,005	96,67 ± 3,50	98,06 ± 1,39
25	95,48 ± 2,12	0,996 ± 0,005	96,67 ± 3,50	98,00 ± 1,54
30	95,19 ± 2,13	0,995 ± 0,005	96,78 ± 3,33	97,89 ± 1,57
35	95,59 ± 2,05	0,995 ± 0,005	96,67 ± 3,61	97,89 ± 1,45
40	95,70 ± 2,16	0,996 ± 0,004	96,78 ± 3,33	97,83 ± 1,46
45	95,63 ± 1,60	0,995 ± 0,004	96,78 ± 3,33	98,06 ± 1,39

Os resultados ao se aplicar os mesmos classificadores para as características extraídas com a decomposição por EWT podem ser vistos nas Tabelas 3 e 4.

Para ambos os métodos de decomposição (EWT e EMD), o desempenho é máximo, considerando o classificador KNN+ANOVA, para N = 11 características. Com o uso de mais do que 11 atributos, o desempenho torna-se relativamente estável, até certo ponto (por volta de 19-20 características), em que a inclusão de novos atributos é prejudicial ao desempenho do modelo. Assim, a inclusão dos parâmetros de desempenho para N > 20 nas Tabelas 1 e 3 tornou-se desnecessária.

Tabela 3. Desempenho de Características extraídas de EWT, ranqueadas por ANOVA e classificação por KNN

N	Exatidão (%)	AUC	Sensitividade (%)	Especificidade (%)
1	71,56 ± 5,04	0,960 ± 0,020	91,89 ± 6,88	96,00 ± 2,75
2	76,33 ± 7,15	0,961 ± 0,020	93,00 ± 4,23	96,50 ± 2,45
3	81,56 ± 6,02	0,967 ± 0,022	94,11 ± 4,61	96,39 ± 2,44
4	84,07 ± 5,66	0,973 ± 0,019	93,78 ± 4,77	97,11 ± 2,31
5	85,89 ± 4,97	0,974 ± 0,024	94,67 ± 3,97	97,11 ± 2,14
6	86,26 ± 3,40	0,975 ± 0,022	94,11 ± 4,35	97,17 ± 1,92
7	86,56 ± 3,29	0,974 ± 0,020	94,56 ± 4,67	97,17 ± 1,92
8	86,96 ± 3,20	0,974 ± 0,019	94,56 ± 4,59	97,17 ± 1,81
9	87,07 ± 3,18	0,975 ± 0,019	94,33 ± 4,81	97,22 ± 1,82
10	87,19 ± 3,35	0,976 ± 0,018	94,78 ± 4,17	97,28 ± 1,78
11	87,41 ± 3,32	0,976 ± 0,016	94,78 ± 4,08	97,28 ± 1,83
12	87,41 ± 3,36	0,976 ± 0,016	94,44 ± 3,64	97,11 ± 2,23
13	87,00 ± 3,20	0,977 ± 0,015	94,33 ± 3,83	97,11 ± 2,23
14	86,96 ± 3,13	0,978 ± 0,015	93,78 ± 4,17	97,00 ± 2,21
15	86,85 ± 2,98	0,978 ± 0,014	93,67 ± 4,04	97,00 ± 2,21
16	86,85 ± 3,32	0,977 ± 0,015	93,89 ± 3,92	96,83 ± 2,29
17	87,04 ± 3,36	0,978 ± 0,013	93,67 ± 3,95	96,61 ± 2,64
18	87,59 ± 2,75	0,978 ± 0,013	93,44 ± 4,15	96,61 ± 2,61
19	71,56 ± 5,04	0,960 ± 0,020	91,89 ± 6,88	96,00 ± 2,75
20	76,33 ± 7,15	0,961 ± 0,020	93,00 ± 4,23	96,50 ± 2,45

Tabela 4. Desempenho de Características extraídas de EWT, classificação por Bagging + CART

N	Exatidão (%)	AUC	Sensitividade (%)	Especificidade (%)
1	75,15 ± 4,43	0,965 ± 0,021	92,11 ± 6,10	97,33 ± 1,84
2	81,19 ± 5,94	0,976 ± 0,019	94,33 ± 4,39	97,28 ± 1,93
3	84,33 ± 5,99	0,982 ± 0,017	94,67 ± 4,25	97,56 ± 1,62
4	88,04 ± 4,31	0,984 ± 0,014	95,11 ± 3,89	97,89 ± 1,51
5	88,81 ± 3,55	0,985 ± 0,013	94,44 ± 4,41	97,67 ± 1,55
6	89,44 ± 2,65	0,987 ± 0,010	94,78 ± 4,08	97,94 ± 1,56
7	90,56 ± 2,84	0,988 ± 0,010	94,89 ± 4,08	98,11 ± 1,50
8	90,93 ± 2,82	0,987 ± 0,011	94,78 ± 4,08	98,06 ± 1,46
9	91,37 ± 2,90	0,988 ± 0,011	94,78 ± 4,26	97,94 ± 1,21
10	91,26 ± 2,70	0,987 ± 0,012	94,33 ± 4,56	97,94 ± 1,43
11	91,41 ± 2,70	0,988 ± 0,010	94,44 ± 4,04	98,00 ± 1,34
12	91,74 ± 3,28	0,989 ± 0,010	94,78 ± 4,35	98,22 ± 1,31
13	92,26 ± 2,57	0,991 ± 0,009	94,56 ± 4,24	98,11 ± 1,29
14	92,19 ± 2,90	0,991 ± 0,011	94,56 ± 4,33	98,11 ± 1,29
20	93,19 ± 2,72	0,994 ± 0,005	94,89 ± 4,08	98,33 ± 1,31
30	93,93 ± 2,67	0,995 ± 0,005	95,22 ± 4,17	98,28 ± 1,20
40	94,22 ± 2,60	0,995 ± 0,004	95,11 ± 4,17	98,39 ± 1,27
45	93,89 ± 2,70	0,995 ± 0,005	95,00 ± 4,35	98,28 ± 1,48

Já para a classificação por conjunto de árvores de decisão (CART), a partir de 6-7 características para EMD, e 13-14 para EWT, o desempenho oscila ligeiramente com a adição de novos atributos, atingindo seu ápice com 40 características para ambos.

Três métodos (todos exceto EWT classificado por KNN) obtiveram índices comparáveis com o sumário, apresentado em (Martis et al. 2012), de resultados de trabalhos utilizando as mesmas classes e a mesma base de dados. Os valores de exatidão variaram de 90,7% em (Ghosh-Dastidar & Adeli 2009) até 99,7% em (Acharya et al. 2012). Outros valores incluem (Guler et al. 2005), onde a taxa de exatidão foi de 96,7 %, com a extração de Expoentes

de Lyapunov e classificação por meio de Redes Neurais Recorrentes. Em (Faust et al. 2010), o uso de SVM aplicado às características de máximos e mínimos locais estimados pelo método de Burg resultou em 93.3% de exatidão, 98,33% de sensibilidade e 96.67% de especificidade. Dos quatro métodos, apenas o classificador KNN aplicado à decomposição por EWT, com exatidão máxima de 87.59%, obteve resultado insatisfatório, comparando com a literatura. Porém, os resultados positivos obtidos com o emprego de um classificador mais refinado (Bagging + CART) mostram que a decomposição por EWT tem o potencial de ser utilizada na predição e classificação de crises epiléticas.

Em (Martis et al. 2012), que também emprega EMD, com a extração de características semelhantes, valores de Exatidão, Sensibilidade e Especificidade máximas foram de 95.33%, 98.00% e 97.00%, respectivamente. Como visto na Tabela 2, este estudo obteve resultados semelhantes, porém com maior número de características utilizadas.

Embora os resultados obtidos neste trabalho sejam positivos, a detecção e classificação de crises epiléticas em um ambiente clínico por meio de tal metodologia deve superar uma série de desafios. Por exemplo, a base de dados utilizada é obtida em condições controladas, com menos artefatos e diferenças na dinâmica do EEG do que em um ambiente clínico. Além disso, o pequeno número relativo de amostras não permitiria a generalização dos resultados e conclusões. Caso a aplicação seja em um sistema de alarme e prevenção de crises, complexidade computacional, robustez e confiabilidade seriam componentes fundamentais a serem avaliados e considerados. Porém, os métodos propostos também têm o potencial de serem aplicados como ferramenta de análise dos mecanismos de funcionamento de crises epiléticas, considerando e extraindo características específicas do sinal ou de seus modos. Por exemplo, acredita-se que a sincronização no disparo dos neurônios tem um papel importante no desenvolvimento de tal condição, de modo que é possível que IMFs ou Modos Empíricos específicos contenham componentes que indicam a presença ou mudança de tal parâmetro, podendo ser utilizado como marcador da iminência de uma crise.

4 Conclusão

O desenvolvimento e aplicação de métodos de extração de características e classificação para epilepsia é uma etapa fundamental, tanto para o entendimento sobre os mecanismos de funcionamento desta condição, quanto para análises clínicas e alertas de iminência de crises convulsivas. Tal tarefa é dificultada pela não-linearidade dos sinais estudados, além do relativo pouco conhecimento dos mecanismos envolvidos.

Os métodos de decomposição e extração de características utilizados neste trabalho se tornam interessantes à medida que utilizam atributos relaciona-

dos a componentes AM-FM que são alterados na presença e possivelmente na iminência de crises epiléticas. Mostramos que a EWT, uma técnica relativamente nova de decomposição de sinais, pode ser utilizada para extração de características relevantes para a classificação e detecção de sinais de EEG que indiquem crises epiléticas. A possibilidade da escolha do número de modos do sinal, dando flexibilidade para a escolha e divisão de componentes específicos, é uma vantagem deste método em relação à EMD. Já a análise por EMD pode ser melhorada com o uso de novos atributos relacionados com o espectro de Hilbert das IMFs (considerando que uma das propriedades das IMFs é a obtenção de uma transformada de Hilbert “bem comportada”). O desenvolvimento posterior de tais metodologias de decomposição e classificação, com as adaptações e ajustes apropriados, terá o intuito de identificar características de mudança no EEG que indiquem a iminência de uma crise epilética, sendo útil inclusive na compreensão dos mecanismos que levam a tal condição.

Agradecimentos

O presente trabalho foi realizado com o apoio financeiro da CAPES – Brasil. Agradecemos também ao CNPq e FAPEMIG pelo desenvolvimento e apoio à pesquisa.

Referências Bibliográficas

- Acharya, U.R. et al., 2012. Application of non-linear and wavelet based features for the automated identification of epileptic EEG signals. *International journal of neural systems*, 22(2), p.1250002.
- Adeli, H., Ghosh-Dastidar, S. & Dadmehr, N., 2007. A wavelet-chaos methodology for analysis of EEGs and EEG subbands to detect seizure and epilepsy. *IEEE transactions on bio-medical engineering*, 54(2), pp.205–11.
- Adeli, H., Zhou, Z. & Dadmehr, N., 2003. Analysis of EEG records in an epileptic patient using wavelet transform. *Journal of neuroscience methods*, 123(1), pp.69–87.
- Andrzejak, R. et al., 2001. Indications of nonlinear deterministic and finite-dimensional structures in time series of brain electrical activity: Dependence on recording region and brain state. *Physical Review E*, 64(6), p.061907.
- Bahcivan, H. & Zhang, N., 2001. Cross-correlation analysis of epileptiform propagation using wavelets. ... in *Medicine and ...*, pp.1804–1807.

- Bajaj, V. & Pachori, R., 2011. Classification of Seizure and Non-seizure EEG Signals using Empirical Mode Decomposition. *IEEE journal of biomedical and health informatics*, 16(6), pp.1135–1142.
- Bajaj, V. & Pachori, R.B., 2013. Epileptic seizure detection based on the instantaneous area of analytic intrinsic mode functions of EEG signals. *Biomedical Engineering Letters*, 3(1), pp.17–21.
- Breiman, L., 1996. Bagging predictors. *Machine learning*, (421).
- Cover, T. & Hart, P., 1967. Nearest neighbor pattern classification. *IEEE Transactions on Information Theory*, 13(1), pp.21–27.
- Daubechies, I., 1992. *Ten Lectures on Wavelets*, Society for Industrial and Applied Mathematics.
- Engel, J., 1989. Seizures and epilepsy. *Annals of Neurology*, 28(3), pp.398–398.
- Faust, O. et al., 2010. Automatic identification of epileptic and background EEG signals using frequency domain parameters. *International journal of neural systems*, 20(2), pp.159–76.
- Frazen, N., 2000. Seizures and epilepsy: hope through research. *Bethesda, MD: NINDS*.
- Ghosh-Dastidar, S. & Adeli, H., 2009. A new supervised learning algorithm for multiple spiking neural networks with application in epilepsy and seizure detection. *Neural networks : the official journal of the International Neural Network Society*, 22(10), pp.1419–31.
- Gilles, J., 2013. Empirical Wavelet Transform. *IEEE Transactions on Signal Processing*, 61(16), pp.3999–4010.
- Guler, N., Ubeyli, E. & Guler, I., 2005. Recurrent neural networks employing Lyapunov exponents for EEG signals classification. *Expert Systems with Applications*, 29(3), pp.506–514.
- Hellman, M., 1970. The Nearest Neighbor Classification Rule with a Reject Option. *IEEE Transactions on Systems Science and Cybernetics*, 6(3), pp.179–185.
- Huang, N.E. et al., 1998. The empirical mode decomposition and the Hilbert spectrum for nonlinear and non-stationary time series analysis. *Proceedings of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 454(1971), pp.903–995.
- Iasemidis, L.D. et al., 2004. Dynamical resetting of the human brain at epileptic seizures: application of nonlinear dynamics and global optimization techniques. *IEEE transactions on bio-medical engineering*, 51(3), pp.493–506.
- Iasemidis, L.D., 2003. Epileptic seizure prediction and control. *IEEE transactions on bio-medical engineering*, 50(5), pp.549–58.
- Labate, D. et al., 2013. Empirical Mode Decomposition vs. Wavelet Decomposition for the Extraction of Respiratory Signal From Single-Channel ECG: A Comparison. *IEEE Sensors Journal*, 13(7), pp.2666–2674.
- Lehnertz, K., 1999. Non-linear time series analysis of intracranial EEG recordings in patients with epilepsy--an overview. *International journal of psychophysiology : official journal of the International Organization of Psychophysiology*, 34(1), pp.45–52.
- Martis, R.J. et al., 2012. Application of empirical mode decomposition (emd) for automated detection of epilepsy using EEG signals. *International journal of neural systems*, 22(6), p.1250027.
- Mormann, F. et al., 2007. Seizure prediction: the long and winding road. *Brain : a journal of neurology*, 130(Pt 2), pp.314–33.
- Oweis, R.J. & Abdulhay, E.W., 2011. Seizure classification in EEG signals utilizing Hilbert-Huang transform. *Biomedical engineering online*, 10(1), p.38.
- Pachori, R.B., 2008. Discrimination between Ictal and Seizure-Free EEG Signals Using Empirical Mode Decomposition. *Research Letters in Communications*, 2008, pp.1–5.
- Tzallas, a T., Tsipouras, M.G. & Fotiadis, D.I., 2007. Automatic seizure detection based on time-frequency analysis and artificial neural networks. *Computational intelligence and neuroscience*, 2007, p.80510.
- Welch, P., 1967. The use of fast Fourier transform for the estimation of power spectra: a method based on time averaging over short, modified periodograms. *IEEE Transactions on audio and electroacoustics*, (2), pp.70–73.